
Расчётно-графическая работа №1

Описание выборки. Оценивание параметров. Доверительные интервалы

Дисциплина:	Математическая статистика
Вариант:	Е-10
Файл данных:	RGR1_E-10_X1-X4_4_.csv
Признаки:	X1, X2, X3, X4
Объём выборки:	$n = 200$
Студент:	Голинский Данила Владимирович
Проверил:	Тузиков Фёдор Николаевич

Содержание

1	Описание данных и постановка задачи	3
2	Этап 1. Первичное описание выборки	3
2.1	Числовые характеристики	3
2.2	Гистограммы и вариационный ряд	5
2.3	Эмпирическая функция распределения	6
3	Этап 2. Гипотезы о законе распределения	6
4	Этап 3. Оценивание параметров (ММ и ММП)	7
4.1	X1: Сдвинутое экспоненциальное $\text{Exp}(\lambda, c)$	7
4.1.1	Метод моментов (ММ)	7
4.1.2	Метод максимального правдоподобия (ММП)	8
4.2	X2: Равномерное $U(a, b)$	8
4.2.1	Метод моментов	8
4.2.2	Метод максимального правдоподобия	8
4.3	X3: Нормальное $\mathcal{N}(\mu, \sigma^2)$	9
4.3.1	Метод моментов	9
4.3.2	ММП	9
4.4	X4: Нормальное $\mathcal{N}(\mu, \sigma^2)$	9
5	Этап 4. Оценка вероятности $P(X > x_0)$	10
6	Этап 5. Работа с группированными данными	11
6.1	Метод построения групп	11
6.2	Формулы для группированных данных	11
6.3	Таблица группировки для X1	12
6.4	Сравнение точных и групповых оценок	12
7	Этап 6. Доверительные интервалы	13
7.1	Теоретические основы	13
7.2	Асимптотические ДИ для МО (все четыре признака)	14
7.3	Точные ДИ для нормальных признаков X3 и X4	14

7.4	Интерпретация доверительных интервалов	15
8	Этап 7. Итоговые выводы	16
8.1	Сводная таблица результатов	16
8.2	Содержательные выводы по каждому признаку	16
	Приложение. Теоретические формулы и инструменты	17

Описание данных и постановка задачи

В данной работе исследуются четыре числовых признака (X_1, X_2, X_3, X_4) из выборки объёма $n = 200$ наблюдений (вариант E-10). Каждый признак анализируется независимо. Цель работы — пройти полный статистический цикл:

1. первичное описание (вариационный ряд, гистограммы, числовые характеристики);
2. выдвинуть гипотезу о законе распределения каждого признака;
3. оценить параметры двумя методами — методом моментов (ММ) и методом максимального правдоподобия (ММП);
4. оценить вероятность события $P(X > x_0)$ эмпирически и параметрически;
5. проанализировать группированные данные;
6. построить доверительные интервалы (ДИ) для параметров.

Инструменты: Python 3, библиотеки `numpy`, `scipy.stats`, `matplotlib`, `pandas`.

Фрагмент данных (первые 10 наблюдений):

Таблица 1: Фрагмент исходной выборки (наблюдения 1–10)

i	X_1	X_2	X_3	X_4
1	0,47	1,32	0,06	0,19
2	2,76	0,44	0,11	1,73
3	2,81	0,74	0,08	1,32
4	1,02	0,47	0,05	1,77
5	1,41	1,19	0,05	−0,42
6	0,56	1,33	−0,05	0,07
7	1,92	0,76	0,17	−0,26
8	3,63	0,15	0,10	1,83
9	3,10	0,68	0,06	1,91
10	2,84	1,34	0,03	−0,31

Этап 1. Первичное описание выборки

Числовые характеристики

Для каждого признака вычислены основные статистики: выборочное среднее $\bar{x}$, медиана Me , несмещённая дисперсия s^2 и стандартное отклонение s , первый и третий квартили Q_1, Q_3 , коэффициенты асимметрии и эксцесса.

Таблица 2: Числовые характеристики четырёх признаков ($n = 200$)

Показатель	X1	X2	X3	X4
Среднее $\bar{x}$	2,1078	0,7706	0,0820	0,7011
Медиана Me	1,4800	0,7500	0,0800	0,5800
Дисперсия s^2	3,4573	0,1356	0,0032	0,8601
Ст. откл. s	1,8594	0,3683	0,0563	0,9274
Q_1 (25-й перцент.)	0,7450	0,4575	0,0500	-0,2000
Q_3 (75-й перцент.)	2,8450	1,1100	0,1200	1,6125
Минимум	0,3200	0,1200	-0,0600	-0,6300
Максимум	11,5300	1,3800	0,2200	2,0800
Коэф. асимметрии	1,8969	0,0499	-0,1211	0,0361
Эксцесс (избыточный)	4,4197	-1,2053	-0,1675	-1,8178

Комментарии к таблице:

- **X1:** значительная правосторонняя асимметрия (1,90) — среднее сильно превышает медиану. Большой эксцесс (4,42) указывает на «тяжёлый» правый хвост.
- **X2:** асимметрия близка к нулю (0,05), эксцесс отрицательный (-1,21) — характерная черта равномерного распределения (у него теоретический эксцесс $= -6/5 = -1,2$).
- **X3:** почти нулевые асимметрия и эксцесс — сильный аргумент в пользу нормального распределения.
- **X4:** нулевая асимметрия (0,04), но сильно отрицательный эксцесс (-1,82) — плоский двухпиковый вид гистограммы, что может указывать на смесь двух нормальных законов. В первом приближении аппроксимируется нормальным распределением.

Гистограммы и вариационный ряд

РГР I · Вариант E-10 | Гистограммы и подогнанные распределения




Рис. 1: Гистограммы четырёх признаков. Вертикальные линии: оранжевая пунктирная — среднее $\bar{x}$, зелёная точечная — медиана Me .

На рис. 1 видно:

- **X1** — крутой спуск слева, длинный «хвост» вправо. Характерная форма экспоненциального закона.
- **X2** — практически прямоугольная гистограмма с равномерно заполненными бинами. Признак равномерного распределения.
- **X3** — симметричный колокол с центром около 0,082. Узкий диапазон значений $(-0,06 \dots 0,22)$.
- **X4** — два видимых «горба» вблизи $-0,2$ и $+1,6$, что объясняется дискретной природой генерирующего процесса (смесь двух нормальных). Среднее и медиана разнесены, хотя асимметрия номинально мала.

Эмпирическая функция распределения




Рис. 2: Эмпирические функции распределения $F_n(x)$ для каждого признака.

Эмпирическая функция распределения строится по формуле:

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}[x_{(i)} \leq x],$$

где $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$ — вариационный ряд (упорядоченные наблюдения). При $n = 200$ шаг ступеней составляет $1/200 = 0,005$.

Этап 2. Гипотезы о законе распределения

На основании визуального анализа гистограмм и числовых характеристик (таблица 2) формулируются следующие гипотезы:

Таблица 3: Гипотезы о законах распределения признаков

Признак	Модель	Обозначение	Обоснование
X_1	Экспоненциальное со сдвигом	$\text{Exp}(\lambda, c)$	Правосторонняя асимметрия ($1,90 < \bar{x} < \text{Me}$, все значения > 0 , длинный правый хвост)
X_2	Равномерное	$U(a, b)$	Прямоугольная гистограмма, эксцесс $\approx -1,2$ (теорет. = $-6/5$ для $U(a, b)$), $\bar{x} \approx \text{Me}$
X_3	Нормальное	$\mathcal{N}(\mu, \sigma^2)$	Симметричная колоколообразная гистограмма, асимметрия ≈ 0 , эксцесс ≈ 0
X_4	Нормальное	$\mathcal{N}(\mu, \sigma^2)$	Симметрия (asym ≈ 0), смесь двух нормальных; в первом приближении — одно нормальное с большой дисперсией

Этап 3. Оценивание параметров (ММ и ММП)

Х1: Сдвинутое экспоненциальное $\text{Exp}(\lambda, c)$

Плотность сдвинутого экспоненциального распределения:

$$f(x) = \lambda e^{-\lambda(x-c)}, \quad x \geq c, \quad \lambda > 0.$$

Теоретические моменты: $\mathbb{E}[X] = c + \frac{1}{\lambda}$, $\mathbb{D}[X] = \frac{1}{\lambda^2}$.

4.1.1 Метод моментов (ММ)

Приравниваем первый теоретический момент к выборочному среднему:

$$c + \frac{1}{\lambda} = \bar{x} \implies \frac{1}{\lambda} = \bar{x} - c.$$

Нижняя граница c оценивается как минимум выборки: $\hat{c}_{\text{ММ}} = x_{(1)} = 0,3200$. Тогда:

$$\hat{\lambda}_{\text{ММ}} = \frac{1}{\bar{x} - x_{(1)}} = \frac{1}{2,1078 - 0,3200} = \frac{1}{1,7878} = 0,5593.$$

4.1.2 Метод максимального правдоподобия (ММП)

Функция правдоподобия:

$$L(\lambda, c \mid x_1, \dots, x_n) = \prod_{i=1}^n \lambda e^{-\lambda(x_i - c)} = \lambda^n \exp\left(-\lambda \sum_{i=1}^n (x_i - c)\right).$$

Логарифмическое правдоподобие:

$$\ell(\lambda, c) = n \ln \lambda - \lambda \sum_{i=1}^n (x_i - c).$$

Так как ℓ возрастает по c , то $\hat{c}_{\text{MLE}} = x_{(1)} = 0,3200$. Дифференцируя по λ :

$$\frac{\partial \ell}{\partial \lambda} = \frac{n}{\lambda} - \sum_{i=1}^n (x_i - \hat{c}) = 0 \implies \hat{\lambda}_{\text{MLE}} = \frac{n}{\sum_{i=1}^n (x_i - \hat{c})} = \frac{1}{\bar{x} - \hat{c}} = 0,5593.$$

В данном случае оценки ММ и ММП совпадают:

$$\boxed{\hat{c} = 0,3200, \quad \hat{\lambda} = 0,5593.}$$

Проверка: $\hat{c} + 1/\hat{\lambda} = 0,3200 + 1/0,5593 = 0,3200 + 1,7878 = 2,1078 = \bar{x}$.

Х2: Равномерное $U(a, b)$

Плотность: $f(x) = \frac{1}{b-a}$, $x \in [a, b]$. Моменты: $\mathbb{E}[X] = \frac{a+b}{2}$, $\mathbb{D}[X] = \frac{(b-a)^2}{12}$.

4.2.1 Метод моментов

Из системы:

$$\frac{\hat{a} + \hat{b}}{2} = \bar{x}, \quad \frac{(\hat{b} - \hat{a})^2}{12} = s^2$$

получаем:

$$\hat{b} - \hat{a} = 2\sqrt{3}s = 2\sqrt{3} \cdot 0,3683 = 1,2756.$$

$$\hat{a}_{\text{MM}} = \bar{x} - \sqrt{3}s = 0,7706 - \sqrt{3} \cdot 0,3683 = 0,7706 - 0,6378 = 0,1328.$$

$$\hat{b}_{\text{MM}} = \bar{x} + \sqrt{3}s = 0,7706 + 0,6378 = 1,4085.$$

4.2.2 Метод максимального правдоподобия

Для равномерного распределения: $\hat{a}_{\text{MLE}} = x_{(1)} = 0,1200$, $\hat{b}_{\text{MLE}} = x_{(n)} = 1,3800$.

Таблица 4: Сравнение оценок параметров $U(a, b)$

Метод	$\hat{a}$	$\hat{b}$
Метод моментов	0,1328	1,4085
ММП	0,1200	1,3800

Оценки близки. ММП даёт более «сжатый» интервал, потому что опирается только на экстремальные наблюдения.

Х3: Нормальное $\mathcal{N}(\mu, \sigma^2)$

Плотность: $f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$.

4.3.1 Метод моментов

$$\hat{\mu}_{\text{ММ}} = \bar{x} = 0,0820, \hat{\sigma}_{\text{ММ}} = s = 0,0563, \hat{\sigma}_{\text{ММ}}^2 = 0,003169.$$

4.3.2 ММП

Для нормального распределения: $\hat{\mu}_{\text{MLE}} = \bar{x} = 0,0820, \hat{\sigma}_{\text{MLE}}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = 0,003153$ (смещённая оценка). В пределе при $n \rightarrow \infty$ обе оценки совпадают.

$$\boxed{\hat{\mu} = 0,0820, \quad \hat{\sigma}_{\text{ММ}} = 0,0563, \quad \hat{\sigma}_{\text{MLE}} = 0,0561.}$$

Х4: Нормальное $\mathcal{N}(\mu, \sigma^2)$

$$\hat{\mu}_{\text{ММ}} = \hat{\mu}_{\text{MLE}} = \bar{x} = 0,7011, \hat{\sigma}_{\text{ММ}} = s = 0,9274, \hat{\sigma}_{\text{MLE}} = 0,9251.$$

$$\boxed{\hat{\mu} = 0,7011, \quad \hat{\sigma} \approx 0,927.}$$

Замечание о двухмодальности Х4: гистограмма Х4 имеет два явных пика вблизи $-0,2$ и $+1,6$. Это означает, что генеральная совокупность, вероятно, является смесью двух нормальных законов. Тем не менее в рамках данной работы используется одна нормальная модель с широкой дисперсией как первое приближение.




Рис. 3: Гистограммы с подогнанными теоретическими распределениями. Синяя штриховая линия — оценки методом моментов, красная сплошная — ММП.

Этап 4. Оценка вероятности $P(X > x_0)$

Для каждого признака выбирается содержательный пороговый уровень x_0 и вычисляется вероятность двумя способами: *эмпирически* (доля наблюдений выше порога) и *параметрически* (через теоретическую функцию распределения с подставленными оценками ММП).

Таблица 5: Оценки вероятности $P(X > x_0)$

Признак	Порог x_0	Обоснование	$P_{\text{эмп}}$	$P_{\text{мод}}$	Расхождение
X_1	$\bar{x} = 2,1078$	среднее	0,375	0,368	0,007
X_2	$(a + b)/2 = 0,750$	центр отрезка	0,490	0,500	0,010
X_3	$\hat{\mu} + \hat{\sigma} = 0,1381$	правило 1σ	0,180	0,159	0,021
X_4	$\hat{\mu} = 0,7011$	среднее	0,500	0,500	0,000

Детали расчётов

X1: $P(X_1 > x_0) = e^{-\lambda(x_0 - c)} = e^{-0,5593 \cdot (2,1078 - 0,3200)} = e^{-0,5593 \cdot 1,7878} = e^{-1,0000} = 0,3679$.

$$\mathbf{X2:} \quad P(X_2 > x_0) = \frac{b - x_0}{b - a} = \frac{1,38 - 0,75}{1,38 - 0,12} = \frac{0,63}{1,26} = 0,5000.$$

$$\mathbf{X3:} \quad P(X_3 > \hat{\mu} + \hat{\sigma}) = 1 - \Phi\left(\frac{(\hat{\mu} + \hat{\sigma}) - \hat{\mu}}{\hat{\sigma}}\right) = 1 - \Phi(1) \approx 0,1587.$$

$$\mathbf{X4:} \quad P(X_4 > \hat{\mu}) = 1 - \Phi(0) = 0,5000.$$

Вывод: расхождения между эмпирическими и модельными оценками невелики (не более 2,1 п.п.), что подтверждает адекватность выбранных моделей.

Этап 5. Работа с группированными данными

Метод построения групп

Число групп выбирается по формуле Стёрджеса: $k = \lceil 1 + 3,322 \cdot \lg n \rceil$. При $n = 200$: $k = \lceil 1 + 3,322 \cdot \lg 200 \rceil = \lceil 1 + 3,322 \cdot 2,301 \rceil = \lceil 8,645 \rceil = 9$.

Границы интервалов: равномерное разбиение $[x_{\min}, x_{\max}]$ на 9 частей. Для каждого интервала вычисляются: середина $z_j = \frac{a_j + a_{j+1}}{2}$ и число наблюдений n_j .

Формулы для группированных данных

Выборочное среднее по сгруппированным данным:

$$\bar{x}_{\text{гр}} = \frac{1}{n} \sum_{j=1}^k n_j z_j.$$

Несмещённая дисперсия:

$$s_{\text{гр}}^2 = \frac{1}{n - 1} \sum_{j=1}^k n_j (z_j - \bar{x}_{\text{гр}})^2.$$

Таблица группировки для X1Таблица 6: Группированные данные для X_1 ($k = 9$ интервалов, $n = 200$)

Интервал $[a_j, a_{j+1})$	Середина z_j	n_j	n_j/n	$n_j \cdot z_j$
[0,320; 1,566)	0,943	109	0,5450	102,787
[1,566; 2,811)	2,188	39	0,1950	85,332
[2,811; 4,057)	3,434	26	0,1300	89,284
[4,057; 5,303)	4,679	12	0,0600	56,148
[5,303; 6,548)	5,925	7	0,0350	41,475
[6,548; 7,794)	7,171	2	0,0100	14,342
[7,794; 9,039)	8,416	4	0,0200	33,664
[9,039; 10,285)	9,662	0	0,0000	0,000
[10,285; 11,530]	10,907	1	0,0050	10,907
Итого	—	200	1,0000	433,939

Группированное среднее: $\bar{x}_{\text{гр}} = 433,939/200 = 2,1697$. Группированное стандартное отклонение: $s_{\text{гр}} = 1,8244$.

Сравнение точных и групповых оценокТаблица 7: Точность группированных оценок по сравнению с точными ($k = 9$)

Признак	$\bar{x}_{\text{точн}}$	$\bar{x}_{\text{гр}}$	$ \Delta \bar{x} $	$s_{\text{точн}}$	$s_{\text{гр}}$	$ \Delta s $
X1	2,1078	2,1697	0,0619	1,8594	1,8244	0,0350
X2	0,7706	0,7738	0,0031	0,3683	0,3622	0,0060
X3	0,0820	0,0826	0,0007	0,0563	0,0581	0,0018
X4	0,7011	0,6964	0,0047	0,9274	0,9351	0,0077




Рис. 4: Группированные данные. Чёрная пунктирная линия — точное среднее, красная точечная — среднее по группированным данным.

Вывод: при $k = 9$ группах и $n = 200$ потеря точности минимальна. Наибольшее отклонение — у X_1 ($\Delta\bar{x} = 0,062$) из-за большого разброса данных. Для признаков X_2, X_3, X_4 ошибка практически нулевая.

Этап 6. Доверительные интервалы

Теоретические основы

Асимптотический ДИ для МО (применим для любого распределения при больших n , ЦПТ):

$$\left(\bar{x} - z_{1-\alpha/2} \cdot \frac{s}{\sqrt{n}}, \bar{x} + z_{1-\alpha/2} \cdot \frac{s}{\sqrt{n}} \right),$$

где $z_{0,975} = 1,9600$.

Точный ДИ для μ нормального распределения (при неизвестном σ^2):

$$\left(\bar{x} - t_{1-\alpha/2; n-1} \cdot \frac{s}{\sqrt{n}}, \bar{x} + t_{1-\alpha/2; n-1} \cdot \frac{s}{\sqrt{n}} \right),$$

где $t_{0,975;199} = 1,9720$.

Точный ДИ для σ^2 нормального распределения (χ^2 -распределение):

$$\left(\frac{(n-1)s^2}{\chi_{1-\alpha/2; n-1}^2}, \frac{(n-1)s^2}{\chi_{\alpha/2; n-1}^2} \right),$$

где $\chi_{0,025;199}^2 = 161,826$, $\chi_{0,975;199}^2 = 239,960$.

Асимптотические ДИ для МО (все четыре признака)

Таблица 8: Асимптотические 95% доверительные интервалы для μ

Признак	$\bar{x}$	s	$SE = s/\sqrt{n}$	ДИ нижняя	ДИ верхняя
X1	2,1078	1,8594	0,1315	1,8501	2,3655
X2	0,7706	0,3683	0,0260	0,7196	0,8217
X3	0,0820	0,0563	0,0040	0,0741	0,0898
X4	0,7011	0,9274	0,0656	0,5725	0,8296

Точные ДИ для нормальных признаков X3 и X4

X3: ДИ для μ

$$SE = \frac{s}{\sqrt{n}} = \frac{0,0563}{\sqrt{200}} = 0,003981.$$

Точный (Стьюдент): $\mu \in (0,0820 - 1,9720 \cdot 0,003981; 0,0820 + 1,9720 \cdot 0,003981) = (0,0741; 0,0898)$

Асимпт.: $\mu \in (0,0741; 0,0898)$.

При $n = 200$ разница между точным и асимптотическим ДИ пренебрежимо мала.

X3: ДИ для σ^2

$$s^2 = 0,003169, \quad (n-1)s^2 = 199 \cdot 0,003169 = 0,6306.$$

$$\sigma^2 \in \left(\frac{0,6306}{239,960}; \frac{0,6306}{161,826} \right) = (0,002628; 0,003896).$$

$$\sigma \in (\sqrt{0,002628}; \sqrt{0,003896}) = (0,0513; 0,0624).$$

X4: ДИ для μ

$$SE = \frac{0,9274}{\sqrt{200}} = 0,06557.$$

$\mu \in (0,7011 - 1,9720 \cdot 0,06557; 0,7011 + 1,9720 \cdot 0,06557) = (0,5717; 0,8304).$

X4: ДИ для σ^2

$$s^2 = 0,8601, \quad (n-1)s^2 = 199 \cdot 0,8601 = 171,161.$$

$$\sigma^2 \in \left(\frac{171,161}{239,960}; \frac{171,161}{161,826} \right) = (0,7133; 1,0577).$$

$$\sigma \in (0,8446; 1,0284).$$

Интерпретация доверительных интервалов

Доверительный интервал **не** означает, что с вероятностью 95% параметр лежит в данном конкретном интервале. Правильная интерпретация: если бы мы повторяли эксперимент многократно и каждый раз строили 95%-ный ДИ, то **примерно 95% таких интервалов** накрывали бы истинное значение параметра. Конкретный построенный интервал либо покрывает истинное значение, либо нет — вероятностной неопределённости здесь нет.

Более узкий ДИ для X_3 (ширина 0,0156) объясняется **малым разбросом** данных ($s = 0,056$). Широкий ДИ для X_1 (ширина 0,515) отражает **высокую вариабельность** ($s = 1,859$) экспоненциального распределения.




Рис. 5: Точечные оценки $\hat{\mu}$ и 95% доверительные интервалы для четырех признаков.

Этап 7. Итоговые выводы

Сводная таблица результатов

Таблица 9: Итоговая сводка: модели, параметры, ДИ

Признак	Модель	Параметры (ММП)	95% ДИ для μ	Ширина ДИ
X_1	$\text{Exp}(\lambda, c)$	$c=0,320, \lambda=0,559$	(1,850; 2,366)	0,515
X_2	$U(a, b)$	$a=0,120, b=1,380$	(0,720; 0,822)	0,102
X_3	$\mathcal{N}(\mu, \sigma^2)$	$\mu=0,082, \sigma=0,056$	(0,074; 0,090)	0,016
X_4	$\mathcal{N}(\mu, \sigma^2)$	$\mu=0,701, \sigma=0,925$	(0,572; 0,830)	0,257

Содержательные выводы по каждому признаку

Х1. Признак моделируется сдвинутым экспоненциальным законом $\text{Exp}(\lambda = 0,559, c = 0,320)$. Нижняя граница $c = 0,320$ указывает на существование минимального «порогового» значения. Высокая правосторонняя асимметрия ($s = 1,859, \text{skew} = 1,897$) означает, что большинство значений малы, но встречаются редкие очень большие наблюдения (максимум 11,53). Практически это может моделировать время ожидания, задержки, нагрузки с тяжёлыми хвостами.

Х2. Равномерный закон $U(0,120, 1,380)$ хорошо описывает данные: эмпирический эксцесс $(-1,205)$ близок к теоретическому $(-1,200)$, все частоты в гистограмме примерно одинаковы. Узкий ДИ для μ (ширина 0,102) говорит о высокой точности оценки среднего.

Х3. Нормальный закон $\mathcal{N}(0,082; 0,056^2)$ — наилучшая из трёх моделей: и по критерию асимметрии, и по эксцессу. Очень малый разброс ($s = 0,056$) и узкий ДИ для μ (ширина 0,016). ДИ для дисперсии: (0,00263; 0,00390).

Х4. Несмотря на визуальную двухмодальность, признак в первом приближении описывается нормальным законом с широкой дисперсией $\sigma^2 \approx 0,86$. Истинная модель, по всей видимости, является смесью двух нормальных: $\mathcal{N}(-0,2; \sigma_1^2)$ и $\mathcal{N}(1,6; \sigma_2^2)$. Тем не менее для целей данной работы нормальная аппроксимация допустима.

Группировка. При $k = 9$ интервалах и $n = 200$ потеря информации при группировке незначительна: максимальное отклонение среднего составляет 0,062 единицы (для X_1), дисперсии — 0,035. Это подтверждает, что при $n \geq 100$ группировка практически не искажает оценки.

Сравнение ММ и ММП. Для нормального и экспоненциального распределений оценки обоих методов практически совпадают (разница в 4-м знаке). Для равномерного распределения ММП даёт более «экономную» оценку интервала $([0,12; 1,38]$ против $[0,13; 1,41]$ у ММ), что является его теоретическим преимуществом для данной модели.

Приложение. Теоретические формулы и инструменты

Использованные функции Python:

- `numpy.mean, var, std, median, percentile, sort, log, exp, sqrt, histogram, linspace` — все базовые статистики и операции;
- `scipy.stats.skew, kurtosis` — коэффициенты формы, `norm.pdf/cdf` — плотность/ФР нормального распределения, `t.ppf` — квантиль Стьюдента, `chi2.ppf` — квантиль хи-квадрат, `norm.ppf` — квантиль стандартного нормального;
- `matplotlib.pyplot` — все графики (гистограммы, ECDF, группировка, ДИ).

Квантили для $n = 200$ ($\nu = 199$), уровень $\alpha = 0,05$:

$$z_{0,975} = 1,9600, \quad t_{0,975; 199} = 1,9720,$$
$$\chi_{0,025; 199}^2 = 161,826, \quad \chi_{0,975; 199}^2 = 239,960.$$

Формула числа групп (Стёрджес):

$$k = \lceil 1 + 3,322 \cdot \log_{10} n \rceil.$$

GitHub репозиторий

Исходный код проекта, Python-скрипты и LaTeX-отчёт доступны в GitHub-репозитории:

https://github.com/Solitudek/Mat_Stat_RGR1